

# Prueba técnica Científico de Datos

## Modelo de detección y priorización de fraude en seguros

### 1. Contexto

En el sector asegurador, la detección temprana de posibles casos de fraude permite focalizar esfuerzos de investigación, proteger la sostenibilidad técnica del portafolio y mejorar la eficiencia operativa de los equipos de siniestros, auditoría y gestión del riesgo. Esta prueba busca evaluar la capacidad del candidato para transformar una necesidad de negocio en un problema analítico abordable, construir un modelo predictivo con datos reales o simulados, interpretar sus resultados y comunicar sus hallazgos de forma clara para audiencias técnicas y de negocio.

### 2. Reto técnico

Construir una solución analítica para estimar la probabilidad de que un registro, siniestro, reclamación, transacción o caso del negocio asegurador corresponda a un posible fraude. El candidato deberá trabajar con una única matriz de datos suministrada por la compañía, cuya variable objetivo es FraudeS /N, y desarrollar un flujo completo de análisis y modelado, desde la exploración inicial hasta la sustentación de resultados.

Se dará puntos adicionales si la solución es desarrollada en Databricks Free Edition, en caso contrario deberá ser implementada en Python, Incluyendo Git para control de versiones con un repositorio organizado.

### 3. Alcance esperado del desarrollo

- Entrenar al menos tres alternativas de modelo.

#### Explicabilidad e interpretación

Se espera que el candidato documente y sustente las decisiones adoptadas en cada etapa de la preparación de datos, detallando los supuestos realizados, el manejo de datos faltantes y atípicos, los criterios para la exclusión o conservación de variables, la generación de nuevas características, y las técnicas de ingeniería de variables aplicadas para optimizar el desempeño y la interpretabilidad del modelo de fraude.

Asimismo, deberá identificar y justificar la exclusión de variables con riesgo de fuga de información (data leakage), variables irrelevantes o redundantes. Podrá construir, transformar, derivar, agregar y consolidar las variables que considere convenientes, siempre que dichas decisiones estén sustentadas desde el punto de vista técnico y de negocio, y sean consistentes con la lógica temporal del problema

- Presentar las variables y las métricas más relevantes del modelo final y su interpretación de negocio.
- Usar técnicas apropiadas de interpretabilidad.
- Identificar patrones o segmentos de mayor riesgo.
- Explicar limitaciones del modelo.

## Scoring y arquitectura conceptual

No se exige implementar una solución MLOps completa. Sin embargo, el candidato deberá explicar cómo dejaría preparado el modelo para ser utilizado en un contexto corporativo. La arquitectura puede presentarse a nivel conceptual y debe enfocarse en el flujo de datos, entrenamiento, consumo del score, monitoreo y gobierno mínimo del modelo.

- Describir entradas y salidas esperadas para un proceso de scoring.
- Proponer una frecuencia razonable de actualización del score según el caso de negocio.
- Explicar cómo se consumirían los resultados por equipos de negocio, investigación o auditoría.
- Incluir un diagrama simple de arquitectura con las capas de datos, preparación, modelado, scoring, consumo y monitoreo.
- Mencionar criterios mínimos de monitoreo.

## Presentación final de sustentación

Al cierre de la prueba, el candidato deberá realizar una presentación en PowerPoint o PDF, orientada a una audiencia mixta de analítica, negocio y tecnología. La presentación debe ser breve, concreta y enfocada en decisiones, hallazgos y valor de negocio.

Se deberán grabar, debe ser de máximo 10 minutos.

## 4. Entregables esperados

El candidato deberá entregar una solución clara, reproducible y sustentable. La evaluación privilegiará el criterio analítico y la claridad de las decisiones por encima de la sofisticación innecesaria.

Git con notebook, readme y presentación final.